# Consistency Models

Ibon De Mingo Arroyo  Eloísa Denia García  Matin Esmaeilzadeh

Noviembre de 2026

**Resumen**

[PENDIENTE: ]

## 1. Introducción

Los modelos de difusión [1, 2] son hoy una de las familias de modelos generativos de imágenes con mejores resultados. Su idea consiste en destruir los datos poco a poco añadiéndoles ruido y entrenar una red neuronal que aprenda a invertir ese proceso. El precio de esta calidad es el coste de generación: para obtener una sola imagen hay que partir de ruido puro y eliminarlo paso a paso, evaluando la red en cada uno de ellos. Ho et al. [1] utilizan 1000 pasos por muestra. Formular el proceso como una ecuación diferencial ordinaria, la *probability flow ODE* [2], permite reducir mucho esa cifra, pero sigue siendo necesario evaluar la red decenas de veces por imagen.

Para resolver este problema, Song et al. [3] propusieron los *Consistency Models*. Un modelo de consistencia aprende a llevar cualquier punto de una trayectoria de esa ecuación directamente a su origen, es decir, a la imagen limpia en la que termina la trayectoria. Gracias a ello puede generar una muestra con una sola evaluación de la red. Si se dispone de más presupuesto de cómputo, puede además encadenar varios pasos, volviendo a añadir ruido y eliminándolo de nuevo, para mejorar la calidad. El artículo presenta dos formas de entrenarlos: *consistency distillation* (CD), que destila el conocimiento de un modelo de difusión ya entrenado que actúa como maestro, y *consistency training* (CT), que los entrena desde cero, sin maestro.

El objetivo de este proyecto es reproducir esta metodología a pequeña escala sobre MNIST [4] y medir qué se gana y qué se pierde al reducir el número de pasos de generación. Se ha elegido MNIST porque es un conjunto de datos ligero, que permite entrenar varios modelos completos dentro del plazo del proyecto y sin GPU.

Respecto a la propuesta inicial, el proyecto se ha ampliado en una dirección: además del maestro de difusión, se ha entrenado un segundo maestro basado en Rectified Flow [5], y también se ha destilado en un modelo de consistencia. Esto permite estudiar cómo influye el tipo de maestro en el modelo resultante.

### 1.1. Objetivos

Los objetivos principales planteados en la propuesta del proyecto son:

1. Entrenar un modelo de difusión que sirva como maestro para el modelo de consistencia.
2. Destilar el conocimiento aprendido por el modelo maestro en un modelo de consistencia más rápido.
3. Comparar el modelo de consistencia frente al modelo de difusión en términos de velocidad y calidad de generación.

4. Estudiar los resultados: la aceleración obtenida, la calidad de las imágenes generadas con más o menos pasos y su diversidad, además de otras cuestiones técnicas de interés y las limitaciones encontradas.

Una vez cumplidos estos objetivos, la propuesta contemplaba tres extensiones, en este orden: entrenar el modelo mediante consistency training y compararlo con los anteriores; adaptar la arquitectura a imágenes en color con CIFAR-10 [6]; y desarrollar un modelo de consistencia condicional, capaz de generar un dígito concreto.

Los cuatro objetivos principales se han cumplido. [PENDIENTE: decidir qué extensiones se incluyen en la entrega]

### 1.2. Estructura del documento

La sección 2 describe los modelos implementados (los dos maestros, la destilación a modelos de consistencia y su muestreo), las diferencias respecto al artículo original y cómo se han evaluado los modelos. La sección 3 presenta los resultados obtenidos. Por último, la sección 4 los analiza junto con las limitaciones del trabajo, y la sección 5 recoge las conclusiones.

## 2. Metodología

[PENDIENTE: escribir cuando los modelos sean definitivos. Hay un borrador en `borrador_metodologia.te`

### 2.1. Datos y arquitectura

[PENDIENTE: MNIST y la U-Net común a todos los modelos.]

### 2.2. Modelos maestros

[PENDIENTE: maestro de difusión VE, maestro Rectified Flow y reflow.]

### 2.3. Modelos de consistencia

[PENDIENTE: parametrización, consistency distillation de CM-VE y CM-RF, y consistency training.]

### 2.4. Muestreo de los modelos de consistencia

[PENDIENTE: generación en uno y en varios pasos.]

### 2.5. Diferencias respecto al artículo original

[PENDIENTE: diferencias de la reproducción respecto a Song et al.]

### 2.6. Protocolo de evaluación

**Clasificador de referencia** [PENDIENTE: CNN, 421 642 pesos, 99,00 % en test, 10 épocas.]

**Métricas de calidad y diversidad** [PENDIENTE: FD-MNIST (distancia de Fréchet sobre las 128 features del clasificador, como FID [7]); porcentaje de muestras reconocibles (confianza $> 0{,}9$); entropía de la distribución de dígitos. Explicar por qué FD es la métrica principal: el clasificador marca el 61 % del ruido puro como dígito con confianza alta. Referencias: MNIST real y ruido puro.]

**Medida de tiempos** [PENDIENTE: ms por imagen, NFE, tiempo frente a $N$, hardware (CPU), $N_{\text{eval}} = 2000$.]

# 3. Resultados

[PENDIENTE: todas las figuras y números de esta sección son provisionales. Eloísa está reentrenando CM-RF y los resultados actuales de CM-RF están evaluados de forma incorrecta (con $c_{\text{in}}$, aunque se entrenó sin él). Cuando estén los checkpoints finales, actualizar `MODELS` en `compare.py`, volver a ejecutarlo y revisar el texto, la tabla y las figuras (las figuras se actualizan solas al recompilar).]

## 3.1. Calidad frente al número de pasos

[PENDIENTE: tabla de resultados y comentario.]

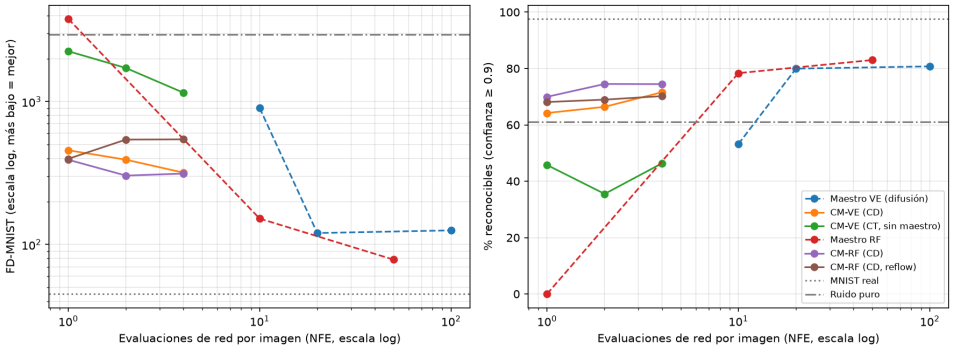



Figura 1: FD-MNIST frente al número de evaluaciones de la red (NFE).

## 3.2. Velocidad de generación

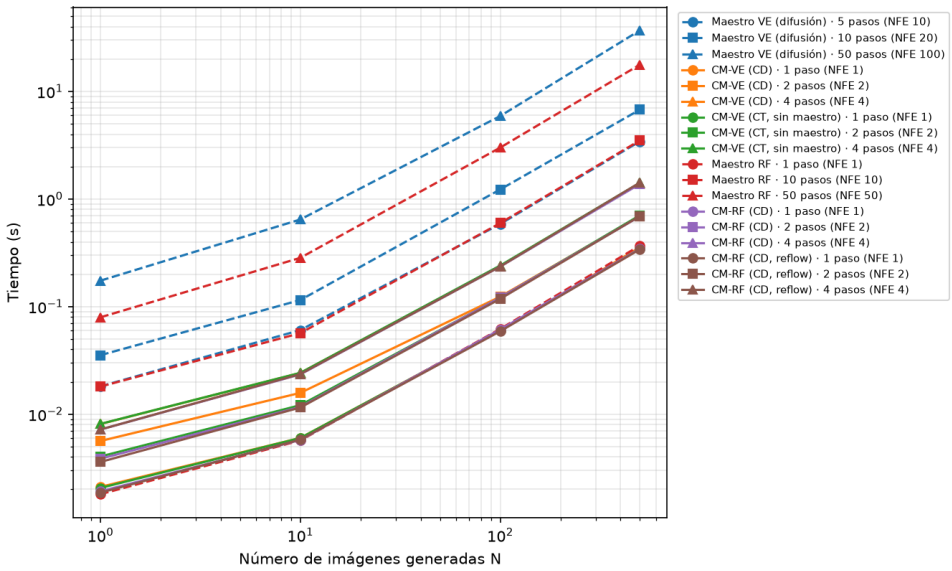



Figura 2: Tiempo de generación frente al número de muestras $N$.

[PENDIENTE: aceleración frente al maestro con 50 y con 10 pasos.]

### 3.3. Diversidad

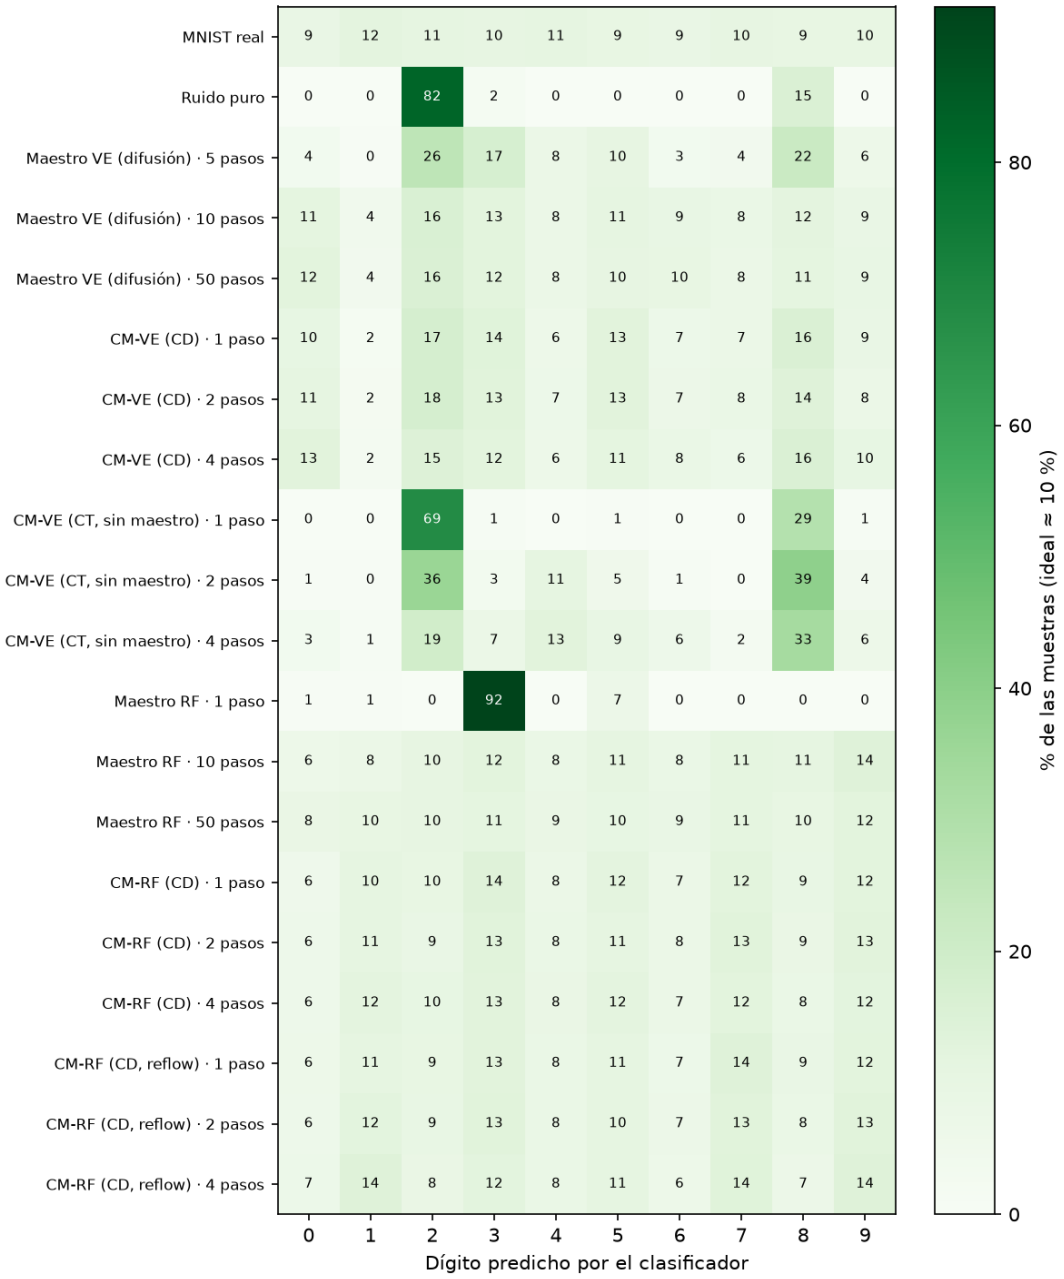



Figura 3: Distribución de dígitos predichos por el clasificador.

[PENDIENTE: entropía, sesgo heredado del maestro (pocos “1”), colapso de CT.]

### 3.4. Inspección visual

## 4. Discusión y limitaciones

[PENDIENTE: qué se gana y qué se pierde al reducir pasos; VE frente a RF como maestro; por qué CT y reflow no funcionan; limitaciones (CPU, tamaño de red, métrica basada en un clasificador propio). Escribir solo con los resultados finales: la comparación VE frente a RF depende del reentrenamiento de CM-RF.]

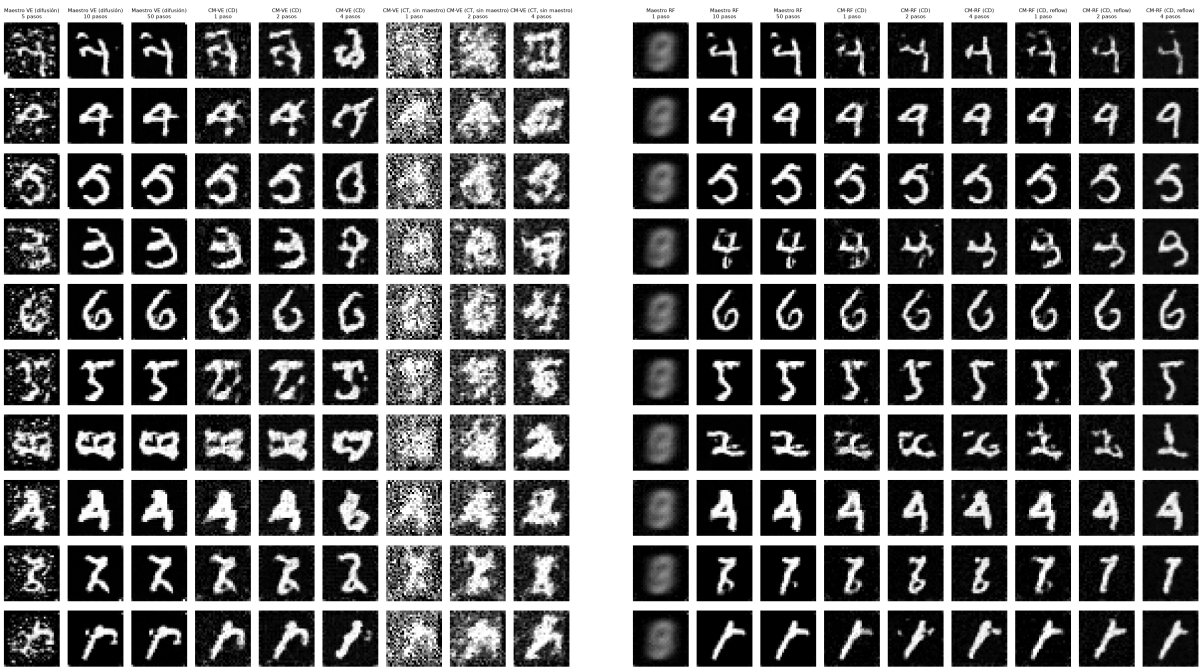


Figura 4: Muestras de la familia VE (izquierda) y RF (derecha).

## 5. Conclusiones y trabajo futuro

[PENDIENTE: cumplimiento de objetivos; extensiones no realizadas (CIFAR-10 [6], modelo condicional) y por qué.]

## Referencias


[1] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, volume 33, pages 6840–6851, 2020.

[2] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*, 2021.

[3] Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever. Consistency models. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *PMLR*, pages 32211–32252, 2023.

[4] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.

[5] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. In *International Conference on Learning Representations*, 2023.

[6] Alex Krizhevsky. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.

[7] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. GANs trained by a two time-scale update rule converge to a local Nash equilibrium. In *Advances in Neural Information Processing Systems*, volume 30, 2017.